

CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

LUCAS DA CRUZ REZENDE

MODELAGEM E OTIMIZAÇÃO DE SISTEMAS DINÂMICOS BIOLÓGICOS
DERIVADOS DE MODELOS BOOLEANOS:

Estudo de estratégias de computação evolucionista para a identificação de parâmetros em
sistemas derivados de modelos booleanos com cinéticas variadas

Leopoldina

2025

LUCAS DA CRUZ REZENDE

**MODELAGEM E OTIMIZAÇÃO DE SISTEMAS DINÂMICOS BIOLÓGICOS
DERIVADOS DE MODELOS BOOLEANOS:**

**Estudo de estratégias de computação evolucionista para a identificação de parâmetros em
sistemas derivados de modelos booleanos com cinéticas variadas**

Trabalho de Conclusão de Curso apresentado
ao Curso de Engenharia de Computação do
Centro Federal de Educação Tecnológica de
Minas Gerais, do Campus Leopoldina, como
parte do requisito para obtenção do título de
Bacharel em Engenharia de Computação.

Orientador: José Eduardo Henriques da Silva

Coorientador: Samuel da Costa Alves Basílio

Leopoldina

2025

XXXX Rezende, Lucas.

2025 Modelagem e Otimização de Sistemas Dinâmicos Biológicos Derivados de Modelos Booleanos : Estudo de estratégias de computação evolucionista para a identificação de parâmetros em sistemas derivados de modelos booleanos com cinéticas variadas / Lucas da Cruz Rezende

Rezende - Leopoldina : CEFET-MG, Ano.

xi, 36 f. : il.

Orientador: José Eduardo Henriques da Silva
Coorientador: Samuel da Costa Alves Basílio

TCC (Graduação) – Centro Federal de Educação Tecnológica de Minas Gerais, Unidade Leopoldina. Engenharia de Computação.

1. Palavra-chave. 2. Palavra-chave. 3. Palavra-chave. I. Sobrenome, Nome do orientador Nome do meio II. Centro Federal de Educação Tecnológica de Minas Gerais. Unidade Leopoldina.

CDU XXX.X

LUCAS DA CRUZ REZENDE

**MODELAGEM E OTIMIZAÇÃO DE SISTEMAS DINÂMICOS BIOLÓGICOS
DERIVADOS DE MODELOS BOOLEANOS : Estudo de estratégias de computação
evolucionista para a identificação de parâmetros em sistemas derivados de modelos
booleanos com cinéticas variadas**

Trabalho de conclusão de curso apresentado ao
Curso de Engenharia de Computação do Centro
Federal de Educação Tecnológica de Minas
Gerais, do Campus Leopoldina, como parte do
requisito para obtenção do título de Bacharel em
Engenharia de Computação.

Aprovado em: Dia de Mês de Ano

Banca Examinadora:

Prof. Dsc. José Eduardo Henriques da Silva- Orientador
CEFET-MG

Prof. Msc. Samuel da Costa Alves Basílio- Coorientador
CEFET-MG

Prof. Msc. Maicom Peters Xavier
CEFET-MG

(Assinaturas Digitais)

**Leopoldina
2025**

MODELAGEM E OTIMIZAÇÃO DE SISTEMAS DINÂMICOS BIOLÓGICOS
DERIVADOS DE MODELOS BOOLEANOS: Estudo de estratégias de computação
evolucionista para a identificação de parâmetros em sistemas derivados de modelos booleanos
com cinéticas variadas

Lucas da Cruz Rezende

José Eduardo Henriques da Silva

Samuel da Costa Alves Basílio

RESUMO

As Redes de Regulação Gênica são cruciais para entender a expressão gênica. Modelos Booleanos, apesar de sua simplicidade e facilidade de representação, oferecem uma visão qualitativa limitada para aplicações práticas, como o desenvolvimento de fármacos. Nesse cenário, modelos contínuos baseados em equações diferenciais são empregados. Contudo, a conversão de modelos Booleanos para contínuos fornece um modelo simbólico da expressão gênica para uma dada cinética, cujos coeficientes numéricos precisa ser posteriormente determinada. Este trabalho foca na avaliação e desenvolvimento de estratégias para transformar modelos Booleanos em contínuos, explorando variações de cinética para representar de forma mais precisa as dinâmicas da regulação genica. Além disso, propõe-se a otimização dos coeficientes numéricos desses modelos por meio de técnicas de computação evolucionista, visando identificar métodos eficazes na minimização do erro e na eficiência computacional. A modelagem precisa das cinéticas e a determinação dos coeficientes numéricos são fundamentais para elucidar fenômenos biológicos e impulsionar o desenvolvimento de fármacos, contribuindo para a medicina personalizada.

Palavras-chave: Redes de Regulação Gênica. Conversão de Modelos. Computação Evolucionista.

**MODELING AND OPTIMIZATION OF BIOLOGICAL DYNAMIC SYSTEMS
DERIVED FROM BOOLEAN MODELS: A Study of Evolutionary Computation Strategies
for Parameter Identification in Systems Derived from Boolean Models with Varied Kinetics**

Lucas da Cruz Rezende

José Eduardo Henriques da Silva

Samuel da Costa Alves Basílio

ABSTRACT

Gene Regulatory Networks are crucial for understanding gene expression. Boolean models, despite their simplicity and ease of representation, offer limited qualitative insight for practical applications such as drug development. In this context, continuous models based on differential equations are employed. However, converting Boolean models into continuous ones provides a symbolic model of gene expression for a given kinetic, whose numerical coefficients must then be determined. This work focuses on the evaluation and development of strategies to transform Boolean models into continuous ones, exploring kinetic variations to more accurately represent gene regulation dynamics. Furthermore, it proposes the optimization of the numerical coefficients of these models using evolutionary computing techniques, aiming to identify effective methods for minimizing error and improving computational efficiency. Accurate modeling of kinetics and the determination of numerical coefficients are essential to elucidate biological phenomena and drive drug development, contributing to personalized medicine.

Keywords: Gene Regulatory Networks; Model Conversion; Evolutionary Computation.

TERMO DE RESPONSABILIDADE POR AUTORIA DO TRABALHO DE CONCLUSÃO DE CURSO

Eu, **LUCAS DA CRUZ REZENDE**, matrícula **12345678**, discente do Curso de Engenharia de Computação, declaro para os devidos fins, que o presente Trabalho de Conclusão de Curso, de título **MODELAGEM E OTIMIZAÇÃO DE SISTEMAS DINÂMICOS BIOLÓGICOS DERIVADOS DE MODELOS BOOLEANOS**, é de minha autoria e que estou ciente dos:

- Artigos 297 a 299 do Código Penal;
- Decreto-Lei n 2.848 de 7 de dezembro de 1940;
- Lei no 9.610, de 19 de fevereiro de 1998, sobre os Direitos Autorais;
- Regulamento Disciplinar Discente do CEFET-MG;
- E que plágio consiste na reprodução de obra alheia e submissão dela como trabalho próprio ou na inclusão, em trabalho próprio, de ideias, textos, tabelas ou ilustrações (quadros, figuras, gráficos, fotografias, retratos, lâminas, desenhos, organogramas, fluxogramas, plantas, mapas e outros) transcritos de obras de terceiros sem a devida e correta citação da referência.

Por ser verdade, e por ter ciência do referido artigo, firmo a presente declaração, isentando o(a) professor(a) orientador(a) **JOSÉ EDUARDO HENRIQUES DA SILVA**, o(a) professor(a) coorientador(a) **SAMUEL DA COSTA ALVES BASÍLIO**, os membros da banca examinadora e o Centro Federal de Educação Tecnológica de Minas Gerais, Campus Leopoldina, de qualquer responsabilidade.

Leopoldina Dia de Mês de Ano

Assinatura do Discente

LISTA DE ILUSTRAÇÕES

Figura 2.1 – Rede de Regulação Gênica com 5 genes (G1-G5). Setas indicam ativação e barras tracejadas, inibição.	17
Figura 2.2 – Fluxograma algoritmo genético.	25
Figura 2.3 – Pseudocódigo da evolução diferencial clássica	30

LISTA DE TABELAS

Tabela 3.1 – Cronograma de desenvolvimento	31
--	----

LISTA DE ABREVIATURAS E SIGLAS

AG Algoritmo Genético

AGS Algoritmo Genético Simples

AE Algoritmo Evolutivo

CE Computação Evolucionista

CMA-ES Covariance Matrix Adaptation Evolution Strategy

DE Evolução Diferencial

EDO Equação Diferencial Ordinária

EE Estratégia Evolutiva

GRN Rede de Regulação Gênica (Gene Regulatory Network)

LISTA DE SÍMBOLOS

$\forall$	Para todo
$\in$	Pertence
x_i	Concentração normalizada da espécie i
$\dot{x}_i$	Taxa de variação temporal de x_i
τ_i	Constante de tempo (tempo de vida) da espécie i
B	Função Booleana original
B_i	Função de atualização Booleana de x_i
B_i^H	HillCube de x_i
N_i	Número de reguladores de x_i
x_{ij}	Valor da j -ésima variável reguladora de x_i
$f_{ij}(x_{ij})$	Função de Hill aplicada a x_{ij}
n	Coefficiente de Hill (inclinação da curva sigmoidal)
k	Limiar de ativação na cinética de Hill
V_0	Velocidade inicial da reação
$V_{\max}$	Velocidade máxima da reação
K_m	Constante de Michaelis
θ	Fração de sítios de ligação ocupados
m	Número de pontos de dados observados
h	Passo temporal na diferenciação numérica
y_k	Valor observado de y no ponto k
y'_k	Aproximação da derivada de y no ponto k
x'	Vetor mutante em evolução diferencial
p	Vetor de perturbação em evolução diferencial
F	Fator de escala em evolução diferencial
u	Vetor de teste (filho) após crossover
Cr	Taxa de crossover
NP	Tamanho da população
μ	Número de progenitores selecionados
λ	Número de descendentes gerados

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Justificativa	13
1.2	Objetivos	14
1.2.1	Objetivo Geral	14
1.2.2	Objetivos Específicos	14
1.3	Metodologia	14
2	Referencial Teórico	16
2.1	Biologia Sistêmica	16
2.2	Redes de Regulação Gênica	16
2.3	Modelagem de Redes de Regulação Gênica	17
2.3.1	Modelos Discretos	18
2.3.2	Modelos Contínuos	18
2.4	Conversão de Modelos Booleanos em Contínuos	19
2.5	Cinéticas	20
2.5.1	Cinética Enzimática	20
2.5.2	Modelo de Michaelis-Menten	21
2.5.3	Modelo de Hill	21
2.5.4	Relação entre Michaelis-Menten e Hill	22
2.6	Regressão Simbólica	23
2.7	Computação Evolucionista	24
2.7.1	Algoritmos genéticos	24
2.7.2	Estratégias evolutivas	26
2.7.3	Evolução diferencial	28
3	Proposta	31
4	Modelagem	32
	REFERÊNCIAS	33

1 INTRODUÇÃO

Entender como os genes se regulam e regulam uns aos outros é um dos grandes desafios da biologia moderna (JACKSON et al., 2020). Por trás de processos fundamentais como o desenvolvimento de organismos, a resposta a estímulos externos e a origem de doenças complexas (MCCALL, 2013), encontra-se uma intrincada rede de interações moleculares conhecida como Rede de Regulação Gênica (Gene Regulatory Network) (GRN), na qual genes, proteínas e outras moléculas se comunicam dentro da célula, influenciando quais genes são ativados ou inibidos em diferentes momentos e contextos (SILVA, 2024).

Na tentativa de compreender e prever o comportamento dessas redes, diversos modelos computacionais vêm sendo propostos sendo eles divididos em três classes: modelos lógicos, modelos contínuos e modelos de nível de molécula única (KARLEBACH; SHAMIR, 2008). Entre eles, os modelos Booleanos ganharam destaque por sua simplicidade conceitual: cada gene é tratado como uma variável binária ativado (1) ou inibido (0) e as interações entre eles são definidas por regras lógicas tais como AND, OR, e NOT, proporcionando uma representação qualitativa eficiente de sistemas biológicos complexos (SILVA et al., 2020).

Para enriquecer modelos Booleanos com dinâmica contínua, Wittmann et al. (2009) propuseram uma metodologia em duas etapas para convertê-los em sistemas de Equação Diferencial Ordinária (EDO)s (WITTMANN et al., 2009). Essa abordagem viabiliza uma representação contínua compatível com a formulação em EDOs, mantendo a estrutura lógica original. Ressalta-se que essa conversão gera apenas um modelo simbólico, sendo necessário posteriormente determinar os coeficientes numéricos por métodos apropriados (SILVA, 2024).

Ainda, é importante ressaltar que os parâmetros cinéticos nos modelos contínuos não variam ao longo da simulação, mas precisam ser definidos a partir de valores numéricos adequados para os coeficientes de inclinação (n) e os limiares (k) das curvas sigmóides. Um exemplo disso ocorre na transição dos modelos BooleCubes para os HillCubes. Nessa etapa, ajustar a cinética das funções de Hill por meio da escolha adequada dos coeficientes de inclinação (n) e dos limiares (k) das curvas sigmóides é essencial para controlar tanto a suavidade quanto o momento exato em que uma resposta gênica é ativada. A cinética não precisa ser necessariamente a de Hill, podendo-se empregar, por exemplo, a de Michaelis–Menten. Dessa forma, busca-se manter a coerência com os estados discretos (0 e 1), ao mesmo tempo em que se preserva a continuidade e o realismo das transições biológicas (WITTMANN et al., 2009).

Para estimar esses parâmetros cinéticos podem ser utilizadas técnicas de otimização baseadas em meta-heurísticas (SILVA et al., 2020). Entre elas, destaca-se as Estratégia Evolutiva (EE). Essas abordagens, inspiradas na evolução natural, conseguem explorar de forma eficiente espaços de busca complexos e de alta dimensionalidade, permitindo encontrar combinações de parâmetros que melhor reproduzem os dados experimentais de expressão gênica ao longo do tempo (SILVA, 2024).

Diante desse cenário, surge a pergunta que orienta este trabalho: **É possível determinar um modelo que represente de forma eficaz a cinética do problema e, ao mesmo tempo, qual técnica de computação evolucionista é mais eficiente para otimizar os parâmetros cinéticos desse modelo contínuo?**

1.1 Justificativa

Modelos Booleanos têm sido amplamente utilizados na modelagem de redes de regulação gênica por sua simplicidade e pela forma eficaz com que conseguem representar, de maneira qualitativa, as interações entre genes (SILVA, 2024). No entanto, esse tipo de abordagem apresenta uma limitação: ela não consegue captar com precisão as variações nos níveis de expressão gênica que ocorrem na realidade (KARLEBACH; SHAMIR, 2008). Isso se deve à natureza binária dos modelos Booleanos, que simplificam a expressão gênica para apenas dois estados, gerando perda de informações sobre a intensidade das interações e as dinâmicas temporais sutis, o que afasta as simulações do comportamento real e complexo das redes de regulação gênica (KAUFFMAN et al., 1993). Por isso, transformar esses modelos em versões contínuas representa um passo essencial para aproximar as simulações do comportamento real dos sistemas biológicos.

O desafio, porém, é que modelos contínuos geralmente exigem informações detalhadas sobre parâmetros cinéticos dados que nem sempre estão disponíveis ou são difíceis de medir (SANGUINETTI et al., 2019). Nesse contexto, técnicas de otimização inspiradas em processos naturais, como as Estratégias Evolutivas, ganham destaque. Elas têm se mostrado eficazes justamente em situações como essa, em que o sistema é complexo e o conhecimento prévio é limitado.

Diante disso, esta pesquisa se justifica pela necessidade de avançar na construção de modelos contínuos mais realistas, a partir de representações Booleanas, e de encontrar métodos computacionais eficientes para ajustar automaticamente seus parâmetros. Essa abordagem

não só melhora a qualidade das representações dos sistemas biológicos, como também amplia a capacidade de prever e interpretar seus comportamentos o que pode trazer contribuições importantes para áreas como biologia sistêmica, medicina personalizada e biotecnologia.

1.2 Objetivos

1.2.1 Objetivo Geral

O objetivo geral deste trabalho é desenvolver um modelo simbólico de cinética adaptativa que represente com precisão a dinâmica das Redes de Regulação Gênica (GRNs), possibilitando uma descrição mais realista dos processos biológicos regulatórios. Além disso, busca-se identificar a estratégia de computação evolucionista mais eficiente para otimizar os parâmetros cinéticos desse modelo.

1.2.2 Objetivos Específicos

- Implementar a metodologia de conversão de modelos Booleanos em sistemas contínuos.
- Explorar diferentes funções sigmóides ajustando parâmetros de inclinação e limiar.
- Testar e validar técnicas de computação evolucionista para otimização de coeficientes numéricos.
- Aplicar o modelo contínuo otimizado em redes biológicas reais para validação.
- Realizar ajuste fino de hiperparâmetros das técnicas de otimização.
- Executar estudo comparativo entre diferentes algoritmos evolucionistas.

1.3 Metodologia

O desenvolvimento da proposta é dividido nas seguintes etapas:

Implementação da conversão de modelos Booleanos em modelos contínuos: Modelos Booleanos, que representam interações genéticas com estados binários, serão convertidos em sistemas de equações diferenciais ordinárias. Para isso, serão utilizados os *BooleCubes*, que aplicam interpolação polinomial multivariada para estender funções lógicas ao intervalo $[0,1]$. Além disso, serão empregados modelos de cinética para suavizar as transições e realizar ajustes,

como os modelos de Hill e Michaelis–Menten, permitindo manter a estrutura lógica original enquanto se incorpora um comportamento contínuo compatível com EDOs.

Análise de variações cinéticas e ajuste de parâmetros: Serão analisados e ajustados os coeficientes de inclinação (n) e limiares (k) utilizando diferentes abordagens cinéticas, como os modelos de Hill e Michaelis-Menten, buscando alinhar os resultados contínuos aos modelos discretos e garantir realismo biológico nas transições.

Aplicação de computação evolucionista para otimização dos parâmetros cinéticos: Técnicas de computação evolucionista serão implementadas para otimizar os parâmetros n e k com base em dados de expressão gênica. A exploração do espaço de busca será guiada de forma eficiente, com ajuste dos hiperparâmetros dos algoritmos para maximizar o desempenho. A qualidade das soluções encontradas será avaliada.

Validação do modelo otimizado em redes biológicas reais: Nesta etapa, o modelo contínuo ajustado será aplicado em Redes de Regulação Gênica reais e será avaliada sua capacidade de representar com precisão a dinâmica das GRNs e de prever comportamentos emergentes de forma biologicamente consistente.

Estudo comparativo entre algoritmos evolucionistas: Será realizada a comparação entre diferentes algoritmos de computação evolucionista utilizados na otimização dos parâmetros. O desempenho será avaliado com métricas de eficiência computacional e precisão biológica, identificando-se a técnica mais adequada para o problema

2 REFERENCIAL TEÓRICO

Neste capítulo são apresentados os fundamentos teóricos necessários para o desenvolvimento desde trabalho. São abordados os conceitos de biologia sistêmica e redes de regulação gênica incluindo suas formas de modelagem contínua e discreta. Em seguida, apresenta-se o processo de conversão de modelos Booleanos para contínuos. Também são apresentados os principais conceitos de cinética enzimática, os modelos de Michaelis-Menten e Hill, e suas relações. E são exploradas técnicas de modelagem baseadas em regressão simbólica e computação evolucionista.

2.1 Biologia Sistêmica

A biologia de sistemas busca entender as interações funcionais de todos os componentes de um sistema biológico ao longo do tempo (LIKIĆ et al., 2010). Esta área interdisciplinar integra biologia, tecnologia e computação, impulsionando avanços mútuos (WANG; SAADATPOUR; ALBERT, 2012). Os sistemas biológicos complexos exibem propriedades emergentes, como a vida, que não são característicos às partes individuais. A robustez permite a manutenção da estabilidade fenotípica frente a perturbações, muitas vezes por meio de *feedback* positivo e negativo (NIJHOUT et al., 2017). A modularidade, por sua vez, organiza o sistema em unidades funcionais, aumentando a robustez e facilitando a evolução (ADEREM, 2005).

A prática da biologia de sistemas envolve captura e integração de dados biológicos de múltiplos níveis hierárquicos, como sequências de DNA e proteínas e interações moleculares. Esses dados são armazenados, visualizados e utilizados para formular modelos gráficos ou matemáticos, que são refinados iterativamente (BADENHORST et al., 2019). O objetivo é prever o comportamento do sistema e redesenhá-lo para novas propriedades emergentes (KITANO, 2001). Nesse contexto, as redes de regulação gênica são um pilar central, representando as interações moleculares que controlam a quantidade dos produtos gênicos (ADEREM, 2005).

2.2 Redes de Regulação Gênica


As Redes de Regulação Gênica são coleções de espécies moleculares e suas interações que, juntas, controlam a abundância de produtos gênicos (IMANI; BRAGA-NETO, 2019). Explicar as relações entre os genes e seus produtos é um dos desafios principais na biologia experimental e computacional (JACKSON et al., 2020). O comportamento das células surge da

interação entre vários elementos da rede, por isso é preciso analisar o conjunto todo, e não só cada componente isolado (MACHADO et al., 2011).

As GRNs são tipicamente representadas como grafos direcionados, onde os nós representam genes e as arestas indicam relações regulatórias, que podem ser de ativação ou inibição (MCCALL, 2013). Uma rede contendo cinco genes (G1-G5) é apresentada na Figura 2.1. As setas indicam relação de ativação e as barras tracejadas, inibição.

- G1 ativa G2 e inibe G4;
- G2 ativa G3 e inibe G4;
- G3 inibe G5;
- G4 ativa G5

Figura 2.1 – Rede de Regulação Gênica com 5 genes (G1-G5). Setas indicam ativação e barras tracejadas, inibição.



Fonte: (SILVA, 2024)

2.3 Modelagem de Redes de Regulação Gênica

Como apresentado anteriormente a modelagem de redes de regulação gênica busca representar, de forma matemática ou computacional, as interações entre genes, produtos gênicos e fatores de transcrição que regulam a expressão gênica. Essas redes são tipicamente representadas por grafos, onde cada nó corresponde a um gene e cada aresta indica influência regulatória entre pares de genes (SCHLITT; BRAZMA, 2007). As abordagens mais comuns para para modelagem de GRNs são os modelos contínuos e discretos.

2.3.1 Modelos Discretos

Os modelos discretos descrevem as relações regulatórias de forma qualitativa. Nestes modelos cada entidade do sistema é representado por um nível discreto. O desenvolvimento temporal do sistema é frequentemente assumido como síncrono, onde o nível de cada entidade é determinado com base nos níveis de seus reguladores no ponto anterior do tempo, de acordo com uma função de regulação (VIJESH et al., 2013).

Dentro dele encontram-se as redes Booleanas, que podem ser modeladas através de circuitos digitais, por utilizarem a mesma álgebra booleana, (SILVA et al., 2020), onde um circuito lógico obedece a um conjunto de regras lógicas e pode ser descrito por uma expressão logica utilizando álgebra booleana. Nela as variáveis assumem valores 0 ou 1. A saída de um circuito lógico pode ser feita por uma tabela verdade, que relaciona cada combinação possível de entradas com as saídas e apresenta como operações básicas OR, AND e NOT (ARNDT; VINGRON, 2007).

Apesar de serem modelos simples, eles podem representar fenômenos biológicos por meio de sua dinâmica e são úteis para inferir relações gênicas a partir de dados experimentais. No entanto, devido ao nível limitado de detalhamento, não conseguem apresentar com clareza aspectos como a autorregulação de fatores de transcrição, além de sua complexidade computacional aumentar com o número de genes, o que se torna um desafio em grandes redes. Ainda assim, muitos avanços permitiram que esses modelos alcançassem poder preditivo suficiente em diversas aplicações (BORNHOLDT, 2008).

2.3.2 Modelos Contínuos

Um modelo contínuo é uma representação matemática em que as concentrações de RNA, proteínas e outras moléculas são tratadas como variáveis contínuas no tempo. Em vez de valores discretos, as quantidades variam, guiadas por equações diferenciais que capturam o comportamento dinâmico do sistema biológico (SILVA, 2024).

Estes modelos descrevem as interações moleculares por meio de funções matemáticas que apresentam como a taxa de cada componente, como a produção ou a degradação de uma proteína, depende das concentrações de outros elementos do sistema. Por exemplo, em sistemas como o S System, temos um conjunto de equações diferenciais ordinárias que quantificam a evolução temporal de RNA e proteínas de forma integrada, obtendo a capacidade de representar dinâmicas complexas (STEUER et al., 2006).

No entanto, apesar de sua precisão e da capacidade de gerar entendimentos sobre a dinâmica do sistema, a aplicação prática desses modelos enfrenta desafios. Eles necessitam de conhecimento de parâmetros cinéticos, que podem ser desconhecidos ou complicados de medir, limitando o uso desses modelos em sistemas biológicos dados escassos (STEUER et al., 2006).

2.4 Conversão de Modelos Booleanos em Contínuos

A metodologia para converter modelos Booleanos em contínuos feita por (WITTMANN et al., 2009) busca estender as regras lógicas discretas para um domínio contínuo, mantendo a essência do comportamento do sistema. Um método canônico para essa transformação envolve o uso de interpolação polinomial multivariada para converter operações lógicas em um sistema de EDOs.

A base dessa metodologia reside na forma como o estado de uma espécie X_i no próximo passo de tempo $(t+1)$ é determinado pelos estados de seus reguladores no tempo t através de uma função de atualização Booleana B_i , expressa como: $X_i(t+1) = B_i(x_{i1}(t), x_{i2}(t), \dots, x_{iN_i}(t)) \in \{0, 1\}$. Esta fórmula fundamental, que caracteriza o comportamento discreto da rede, é o ponto de partida para a conversão.

O primeiro passo envolve a substituição das variáveis Booleanas discretas $x_i \in \{0, 1\}$ por variáveis contínuas $\bar{x}_i \in [0, 1]$. Essas variáveis contínuas podem ser interpretadas como níveis de concentração normalizados entre 0 e 1. Em seguida, as funções de atualização Booleanas B_i precisam ser estendidas para funções contínuas $\bar{B}_i : [0, 1]^N \rightarrow [0, 1]$. Essas funções são chamadas de BooleCubes e são definidas de modo a concordar com a função Booleana original nos vértices do cubo unitário (WITTMANN et al., 2009). A formulação geral de um BooleCube $\bar{B}_i$ é dada por:

$$\bar{B}_i(\bar{x}_1, \dots, \bar{x}_N) := \sum_{x_1=0}^1 \sum_{x_2=0}^1 \cdots \sum_{x_N=0}^1 B(x_1, x_2, \dots, x_N) \prod_{i=1}^N (x_i \bar{x}_i + (1 - x_i)(1 - \bar{x}_i)) \quad (2.1)$$

Onde $B(x_1, \dots, x_N)$ é a função Booleana original. Essa representação é uma forma de soma de produtos no domínio contínuo. BooleCubes são funções suaves e podem ser facilmente diferenciadas e integradas analiticamente (WITTMANN et al., 2009).

Para incorporar o comportamento sigmoidal frequentemente observado nas interações moleculares biológicas, são introduzidas as funções de Hill:

$$f(\bar{x}) = \frac{\bar{x}^n}{\bar{x}^n + k^n} \quad (2.2)$$

Aqui, o coeficiente de Hill n regula a inclinação da curva, refletindo a cooperatividade da interação, e k corresponde a um limiar de ativação. A construção dos HillCubes ocorre pela substituição das variáveis contínuas $\bar{x}_j$ nas expressões dos BooleCubes pelas correspondentes funções de Hill $f(\bar{x}_j)$:

$$\overline{B}_i^H(\overline{x}_{i1}, \dots, \overline{x}_{iN_i}) := \overline{B}_i^l(f_{i1}(\overline{x}_{i1}), f_{i2}(\overline{x}_{i2}), \dots, f_{iN_i}(\overline{x}_{iN_i})) \quad (2.3)$$

Essa abordagem permite que cada interação seja caracterizada por sua própria função de Hill, com parâmetros individualizados, enquanto os BooleCubes se encarregam de acoplar essas interações, preservando a forma sigmoideal das funções de Hill (WITTMANN et al., 2009).

O comportamento temporal das concentrações $\bar{x}_i$ é descrito por um sistema de EDOs, utilizando as funções de atualização contínuas:

$$\dot{\bar{x}}_i = \frac{1}{\tau_i} (\overline{B}_i^H(\overline{x}_{i1}, \dots, \overline{x}_{iN_i}) - \bar{x}_i) \quad (2.4)$$

Nesta formulação, τ_i é um parâmetro que pode ser interpretado como o tempo de vida da espécie X_i . Os parâmetros n e k das funções de Hill, em conjunto com os τ_i , constituem os coeficientes numéricos do modelo contínuo que necessitam ser determinados. A capacidade desses parâmetros em acomodar diferentes escalas de tempo de interações é fundamental. A conversão para HillCubes e a subsequente formulação em EDOs capacitam o modelo contínuo a replicar o comportamento do modelo Booleano original, ao mesmo tempo em que oferece propriedades dinâmicas mais ricas, como a reprodução de perfis temporais de níveis de concentração e a predição de afinidades de ligação para diversos ligantes (WITTMANN et al., 2009).

2.5 Cinéticas

2.5.1 Cinética Enzimática

A cinética enzimática é o estudo das taxas das reações químicas catalisadas por enzimas. As enzimas são catalisadores biológicos que aumentam drasticamente a velocidade de reações específicas sem serem consumidas no processo (BISSWANGER, 2017). Elas fazem isso diminuindo a energia de ativação da reação ($\Delta G^\ddagger$), estabilizando o estado de transição. As

enzimas não afetam o equilíbrio da reação, elas apenas aceleram a taxa na qual a reação atinge o equilíbrio (BOYLE, 2005).

2.5.2 Modelo de Michaelis-Menten

O modelo de Michaelis-Menten estabelece uma relação quantitativa entre a velocidade inicial de uma reação enzimática (V_0) e a concentração do substrato ($[S]$). Proposto por Leonor Michaelis e Maud Menten em 1913, o modelo assume que a enzima se liga reversivelmente ao substrato, formando rapidamente um complexo enzima-substrato (ES). Esse complexo, por sua vez, se decompõe mais lentamente, liberando o produto e restaurando a enzima livre (JOHNSON; GOODY, 2011).

A equação de Michaelis-Menten é:

$$V_0 = \frac{V_{\max} \cdot [S]}{K_m + [S]} \quad (2.5)$$

Onde:

- V_0 é a velocidade inicial da reação.
- $V_{\max}$ é a velocidade máxima da reação, alcançada quando a enzima está saturada com o substrato.
- K_m (constante de Michaelis) é a concentração de substrato na qual a velocidade inicial é metade de $V_{\max}$. K_m pode ser uma medida da afinidade da enzima pelo substrato, especialmente quando a etapa de quebra do complexo ES em E + P é a etapa limitante da velocidade. Um valor menor de K_m indica maior afinidade da enzima pelo substrato.

2.5.3 Modelo de Hill

O modelo de Hill foi apresentado para descrever a relação de equilíbrio entre a tensão de oxigênio e a saturação de hemoglobina. Essa equação é amplamente utilizada em farmacologia para analisar as relações quantitativas fármacos e receptores. Além disso, muitos modelos empregam essa equação para descrever relações não lineares entre dose e resposta de fármacos (GOUTELLE et al., 2008).

A equação de Hill focada na bioquímica é:

$$\log \left(\frac{\theta}{1 - \theta} \right) = n_H \cdot \log[L] - \log K_d \quad (2.6)$$

Onde:

- θ é a fração de sítios de ligação ocupados pelo ligante.
- $[L]$ é a concentração do ligante.
- K_d é a constante de dissociação aparente.
- n_H (coeficiente de Hill) é uma medida do grau de cooperatividade.

Para modelagem continua de redes, usa-se uma forma sigmoideal da equação. Wittmann et al. (2009) aplicam essa abordagem para transformar modelos Booleanos em sistemas contínuos, usando expressões para simular transições binárias.

$$f(\bar{x}) = \frac{\bar{x}^n}{\bar{x}^n + k^n} \quad (2.7)$$

Onde:

- n determina a inclinação da curva.
- k é um limiar.

2.5.4 Relação entre Michaelis-Menten e Hill

Ambos os modelos descrevem a relação entre a concentração do substrato e a velocidade de reação de ou fração de sítios de ligação ocupados (RADEEF, 2025).

O modelo de Michaelis-Menten se aplica a enzima com ligação não cooperativa de um único substrato, ou a sistemas em que a cooperatividade é desprezível (quando o coeficiente de Hill $n_H = 1$) . a curva gerada por esse modelo é hiperbólica (NOËL, 2020).

O modelo de Hill é uma generalização que considera a ligação cooperativa, gerando uma curva de saturação sigmoide. Quando $n_H = 1$, a equação de Hill se reduz à de Michaelis-Menten (LEHNINGER, 2004).

A principal diferença entre os dois é que Michaelis-Menten descreve os sistemas sem interações entre os sítios de ligação, enquanto Hill é voltado para sistemas com múltiplos sítios

de ligação, enquanto Hill é voltado para sistemas com múltiplos sítios cooperativos, onde a ligação de um ligante influencia a afinidade dos demais (BOYLE, 2005).

2.6 Regressão Simbólica

Uma forma de descrever matematicamente um sistema físico ou biológico é utilizando um conjunto de EDOs, pois elas podem apresentar as derivadas temporais das posições físicas ou concentrações químicas conforme seu estado atual (SCHMIDT; LIPSON, 2008). Determinar uma forma simbólica para $f(X, y)$ que resolva um sistema de w equações diferenciais compatível com os dados é um desafio relevante em modelagem (BERNARDINO; BARBOSA, 2010).

Dado um conjunto de dados e uma classe de funções, o problema de encontrar a função que melhor se ajusta aos dados é chamado de regressão. Isso envolve minimizar alguma medida de erro entre o modelo e os dados, usando um método de otimização. Normalmente, a forma da função é fixada, e o objetivo é ajustar seus coeficientes. Mas, quando a estrutura da função não é conhecida, é preciso determinar tanto a forma quanto os parâmetros, isso é chamado de regressão simbólica (AUGUSTO; BARBOSA, 2000).

O objetivo é encontrar o sistema de equações diferenciais $y' = f(x, y) = \{y'_1 = f_1(x, y), y'_2 = f_2(x, y), \dots, y'_n = f_n(x, y)\}$ que descreva o comportamento dos pontos observados (x_k, y_k) , com $y_k = y(x_k)$, para $k = 1, \dots, m$, onde m é o número de dados.

Existem duas abordagens principais para aplicar regressão simbólica a sistemas dinâmicos. O primeiro envolve calcular uma aproximação das derivadas dos dados apenas uma vez, no início do processo, usando por exemplo, a diferenciação numérica de dois pontos, onde:

$$y'_k \approx \frac{y_{k+1} - y_k}{h} \quad (2.8)$$

Para a outra integra-se e compara para cada função gerada pela regressão a curva resultante como os dados. Um método comum é o Runge-Kutta de 4ª ordem:

$$\begin{aligned}
\bar{y}_{k+1} &= \bar{y}_k + \frac{h}{6}(q_1 + 2q_2 + 2q_3 + q_4) \\
q_1 &= f(t_k, \bar{y}_k) \\
q_2 &= f(t_k + \frac{h}{2}, \bar{y}_k + \frac{h}{2}q_1) \\
q_3 &= f(t_k + \frac{h}{2}, \bar{y}_k + \frac{h}{2}q_2) \\
q_4 &= f(t_k + h, \bar{y}_k + hq_3)
\end{aligned} \tag{2.9}$$

Este método possui erro de ordem $O(h^5)$, em contraste com o erro $O(h)$ da diferenciação simples. Entretanto, exige integração a cada avaliação de candidato, aumentando o custo computacional

2.7 Computação Evolucionista

A Computação Evolucionista (CE) é uma área da inteligência artificial que se inspira nos princípios da evolução biológica, propostos por Charles Darwin em sua Teoria da Evolução das Espécies. O mecanismo central dessa teoria é a seleção natural, onde os indivíduos mais adaptados ao seu ambiente possuem maiores chances de sobreviver e se reproduzir, transmitindo suas características favoráveis às futuras gerações (DARWIN, 1859).

A CE surge como uma abordagem poderosa para desenvolver algoritmos robustos e de alto desempenho, capazes de resolver problemas de crescente complexidade dentro de prazos limitados (LOPES; TAKAHASHI, 2011). Diferentemente de algoritmos projetados para problemas específicos, os algoritmos evolutivos Algoritmo Evolutivo (AE) são notavelmente versáteis, aplicáveis a uma vasta gama de desafios com pouca necessidade de adaptação, e frequentemente fornecem soluções de qualidade satisfatória (FONSECA, 2009). Além disso, a CE oferece uma plataforma valiosa para simular e compreender processos evolutivos em um ambiente controlado, possibilitando a realização de experimentos que seriam inviáveis na biologia tradicional (EIBEN; SMITH, 2015).


2.7.1 Algoritmos genéticos

A base dos Algoritmo Genético (AG)s segue a lógica evolutiva onde uma população de soluções candidatas compete por sobrevivência em um ambiente com recursos limitados (MIRJALILI; MIRJALILI, 2019). Em seu modelo clássico como Algoritmo Genético Simples (AGS), é utilizado representação binária, seleção proporcional à aptidão, baixa taxa de mutação e

recombinação com probabilidade fixa (LACERDA; CARVALHO, 1999). Indivíduos com maior aptidão têm maior chance de gerar descendentes por meio de operadores como recombinação e mutação (ZINI, 2009). A cada geração, a nova população substitui completamente a anterior, mesmo com limitações como elitismo e uso fixo de parâmetros. Algumas melhorias como seleção por torneio, elitismo, recombinação uniforme e auto-adaptação de taxas de mutação foram incorporadas ao longo do tempo, dando origem a variações mais desenvolvidas do algoritmo (EIBEN; SMITH, 2015).

A figura 2.3 mostra o método de algoritmo genético proposto por Dastanpour, Ibrahim e Mashinchi (2014), que combina uma rede neural artificial com um algoritmo genético para melhorar a precisão na detecção de instruções. o processo começa com separação do conjunto de dados em partes de treino e teste. A rede neural artificial é treinada com os dados e então realiza a classificação dos dados de teste. Em seguida, os resultados são usados como entrada para o **GA! (GA!)**, que otimiza os parâmetros da rede. Ele busca minimizar o erro e maximizar a taxa de acerto, selecionando subconjuntos de características mais relevantes. No final compara-se performance da rede neural artificial com a otimizada pelo algoritmo genético.

Figura 2.2 – Fluxograma algoritmo genético.



Fonte: (DASTANPOUR; IBRAHIM; MASHINCHI, 2014)

2.7.2 Estratégias evolutivas

As EEs são métodos de otimização inspirados na evolução biológica, projetados para encontrar soluções em espaços contínuos de forma eficiente e adaptativa (BEYER; SCHWEFEL, 2002). Foram desenvolvidas com o objetivo de serem aplicadas em otimização numérica, revelando-se algoritmos robustos e eficientes (COSTA; OLIVEIRA, 2012). Cada indivíduo em uma EE é representado por um vetor de variáveis de solução ($x \in R^n$) acompanhado de um vetor de parâmetros de estratégia (σ), que determina o passo de mutação. A técnica central é a mutação gaussiana: novas soluções x' são geradas por

$$x' = x + \sigma \cdot N(0, 1), \quad (2.10)$$

permitindo exploração contínua do espaço de busca.

O diferencial das EE está na auto adaptação dos parâmetros σ : eles próprios integram o genótipo e evoluem conforme o algoritmo progride, ajustando automaticamente a intensidade das mutações (MEYER-NIEBERG; BEYER, 2007). A recombinação une informações de vários pais para formar filhos, usando seleção discreta para as variáveis x e média aritmética para os σ , garantindo diversidade e estabilidade no processo evolutivo. Após gerar λ descendentes a partir de μ progenitores, aplica-se o esquema de seleção (μ, λ) ou $(\mu + \lambda)$: apenas os melhores μ sobrevivem à próxima geração, assegurando pressão seletiva e capacidade de escapar de ótimos locais (BEYER; SCHWEFEL, 2002). Existem diferentes formas de implementar essa auto-adaptação do σ , como estratégias baseadas em esquemas μ, λ e $\mu + \lambda$, assim como variantes mais elaboradas como Covariance Matrix Adaptation Evolution Strategy (CMA-ES), entre outras (CHOCAT et al., 2015). Essas características fazem das estratégias evolutivas uma boa opção para problemas de otimização em que as variáveis são reais e o terreno de busca exige equilíbrio entre exploração e exploração (EIBEN; SMITH, 2015).

Vale destacar que o modelo apresentado anteriormente é apenas uma das variantes da EE. Existem outras abordagens mais sofisticadas, além de variações nos esquemas de recombinação e mutação.

O algoritmo 1 apresenta o funcionamento geral da ES. O operador de variação é definido por Ψ_V , e o de avaliação é explícito. A população $P^{(t)}$ na geração $t \geq 0$ é um conjunto de indivíduos, onde cada $p \in P^{(t)}$ é uma tupla (x, Ψ) . Os conjuntos Ψ e Ψ_V são parâmetros de estratégia arbitrários. Parâmetros modificados internamente são endógenos. μ é o número de pais, λ de descendentes, e ρ de pais para uma única recombinação. Para esses, $\mu, \rho, \lambda \in N$ e

$$\rho \leq \mu.$$

Algorithm 1 Procedimento geral das estratégias evolutivas (EIBEN; SMITH, 2015)

 Inicialização de $P^{(0)}$ com μ indivíduos

 $t \leftarrow 0$
repeat
 $Q^{(t)} \leftarrow \emptyset$
for $i = 1 \lambda$ **do**

 Amostra ρ pais $p_1, \dots, p_\rho \in P^{(t)}$ uniformemente de maneira aleatória

 $q \leftarrow \text{variação}(p_1, \dots, p_\rho, \Psi_V)$
 $Q^{(t)} \leftarrow Q^{(t)} \cup \{q\}$
end
 $P^{(t+1)} \leftarrow \text{seleção dos } \mu \text{ melhores indivíduos de } Q^{(t)} \cup \{p \in P^{(t)} : \text{idade} < \kappa\}$

 Atualiza Ψ_V
 $\forall p \in P^{(t+1)} : \text{atualiza idade}$
 $t \leftarrow t + 1$
until o critério de parada seja atingido

$\kappa \in N$ define a idade máxima de um indivíduo. Ao contrário dos endógenos, μ , ρ , λ e κ são exógenos, definidos pelo usuário. A configuração de κ influencia diretamente a seleção. Seleção vírgula ($\kappa = 1$) e adição ($\kappa = \infty$) são comuns. A seleção vírgula é geralmente preferida por facilitar o escape de ótimos locais, acompanhar ótimos móveis e evitar que mutações ruins persistam (EIBEN; SMITH, 2015).

A adaptabilidade do parâmetro de mutação é crucial. Operadores de mutação devem permitir que qualquer ponto no espaço de busca seja alcançável, serem imparciais e parametrizados (EIBEN; SMITH, 2015). Uma distribuição normal multivariada satisfaz esses requisitos. A mutação é $N(\zeta, \sigma)$, com ζ (média) = 0 e σ o desvio padrão. A ordem da mutação é importante: $\sigma \rightarrow \sigma'$ e, depois, $x \rightarrow x' = x + N(0, \sigma')$. Um x' é bom se $f(x')$ for bom, e σ' é bom se x' gerado de σ' for bom ($f(x)$ é a função de avaliação) (BÄCK; FOUSSETTE; KRAUSE, 2013).

A primeira ES, a $(1 + 1)$ -ES, gera x' de um progenitor ($x \in R$) por $x' = x + \sigma \cdot N(0, 1)$. x' se torna pai se $f(x') > f(x)$ (maximização) ou $f(x') < f(x)$ (minimização). Inicialmente, σ era fixo. A adaptação do passo de mutação foi introduzida pela "regra do 1/5 de sucesso": se as mutações são bem-sucedidas em $\approx 1/5$ das vezes, não há adaptação; menos, o passo é reduzido; mais, é aumentado. Assim, $\sigma' = \sigma \cdot c^{\{-1, 1\}}$, com $0.817 \leq c \leq 1$ ($c = 0.817$) (SCHWEFEL, 1977). Diversas outras variantes de ES surgiram desde então (BÄCK; FOUSSETTE; KRAUSE, 2013).

2.7.3 Evolução diferencial

O Algoritmo de Evolução Diferencial (DE) é um método aleatório de otimização populacional voltado principalmente para problemas em espaços contínuos (STORN; PRICE, 1997). Ele foi projetado para encontrar soluções aproximadas eficientes em funções objetivo complexas, especialmente quando há múltiplos ótimos locais. A principal inspiração para o nome do método vem do seu mecanismo de mutação diferencial, que utiliza diferenças vetoriais entre indivíduos da população para gerar novas soluções. A partir de uma população de vetores de solução candidatos em R^n , um novo vetor mutante $\mathbf{x}'$ é gerado adicionando-se um vetor de perturbação a um vetor existente,

$$\mathbf{x}' = \mathbf{x} + \mathbf{p} \quad (2.11)$$

Sendo esse vetor de perturbação $\mathbf{p}$ a diferença vetorial escalada de dois outros membros escolhidos aleatoriamente da população,

$$\mathbf{p} = F \cdot (\mathbf{y} - \mathbf{z}) \quad (2.12)$$

onde $F > 0$ é um número real que controla a rapidez com que a população evolui. Após isso, aplica-se um crossover uniforme com taxa C_r , combinando vetor mutado com o original, gerando um vetor de teste $\mathbf{u}$. A seleção é determinística, mantendo o vetor com melhor disposição entre $\mathbf{x}$ e $\mathbf{u}$ (EIBEN; SMITH, 2015).

Os principais parâmetros são: fator de escala F , tamanho da população NP e taxa de crossover C_r . O número de genes herdados do mutante segue uma distribuição binomial. A escolha aleatória dos vetores e a aplicação da mutação fazem da evolução diferencial um algoritmo estocástico, cujo processo é repetido iterativamente até que um critério de parada seja alcançado (ROCHA; SARAMAGO, 2011).

A notação DE/a/b/c define variantes, como DE/rand/1/bin (clássica), onde se especifica o vetor base, o número de diferenças e o tipo de recombinação. A DE se destaca pela simplicidade e eficiência em problemas com variáveis reais (XIANG et al., 2015).

A figura 2.3 apresenta o como funciona a evolução diferencial clássica. Ela inicia com a definição dos parâmetros de controle: o fator de escala da mutação F , a taxa de crossover C_r e o critério de parada (por exemplo, número máximo de gerações ou valor-alvo da função custo) (ELTAEIB; MAHMOOD, 2018). Em seguida, gera-se uma população inicial de NP

vetores-solução $x_j \in R^D$ de forma completamente aleatória dentro dos limites inferiores b_L e superiores b_U do problema, segundo

$$x_{i,j} = b_L + (b_U - b_L) \text{rand}(0, 1), \quad i = 1, \dots, D; \quad j = 1, \dots, NP. \quad (2.13)$$

A cada geração, para cada vetor-alvo x , selecionam-se aleatoriamente três outros vetores distintos v_1, v_2, v_3 da população e calcula-se o vetor mutante

$$v_y = v_3 + F(v_1 - v_2), \quad (2.14)$$

introduzindo exploração ao combinar diferenças entre soluções atuais. Em seguida, constrói-se o vetor de teste v_{trial} por crossover binomial entre v_y e o vetor-alvo x :


$$v_{\text{trial}}[i] = \begin{cases} v_y[i], & \text{se } \text{rand}(0, 1) < Cr, \\ x[i], & \text{caso contrário,} \end{cases} \quad i = 1, \dots, D. \quad (2.15)$$

Finalmente, aplica-se a seleção, comparando as aptidões:

$$x \leftarrow \begin{cases} v_{\text{trial}}, & \text{se } f(v_{\text{trial}}) \leq f(x), \\ x, & \text{caso contrário.} \end{cases} \quad (2.16)$$

Esse ciclo de mutação, crossover e seleção repete-se até que o critério de parada seja satisfeito. Ao final, o melhor vetor encontrado é retornado como solução aproximada do problema de otimização. Esta estratégia é conhecida como DE/rand/1/bin e é amplamente utilizada em problemas contínuos devido à sua simplicidade e eficácia (ELTAEIB; MAHMOOD, 2018).

Figura 2.3 – Pseudocódigo da evolução diferencial clássica



Fonte: (ELTAEIB; MAHMOOD, 2018)

3 PROPOSTA

Neste trabalho, busca-se, inicialmente, implementar a conversão automática de modelos Booleanos para contínuos, a fim de superar as limitações dos modelos binários e capturar a dinâmica complexa das Redes de Regulação Gênica através de sistemas de equações diferenciais ordinárias. Em seguida, será introduzida a modelagem cinética, explorando diferentes cinéticas, permitindo um ajuste preciso das transições do modelo contínuo e assegurando o realismo biológico. O terceiro pilar da proposta envolve a determinação dos coeficientes numéricos dos modelos contínuos. Para abordar a dificuldade de obtenção desses parâmetros cinéticos, o trabalho se concentrará na otimização dos coeficientes por meio de técnicas de computação evolucionista. E por último, será realizado um estudo comparativo das técnicas de otimização baseadas em computação evolucionista, como Estratégias Evolutivas e Evolução Diferencial. A análise se dará em termos da qualidade da solução, custo computacional e complexidade algorítmica, visando identificar os métodos mais eficientes para a otimização dos parâmetros cinéticos e, assim, contribuir para o avanço da biologia sistêmica e medicina personalizada. A execução dessas etapas será organizada conforme o cronograma 3.1.

Tabela 3.1 – Cronograma de desenvolvimento

[illegible]

4 MODELAGEM

Neste trabalho, busca-se, inicialmente, implementar a conversão automática de modelos Booleanos para contínuos, a fim de superar as limitações dos modelos binários e capturar a dinâmica complexa das Redes de Regulação Gênica através de sistemas de equações diferenciais ordinárias. Em seguida, será introduzida a modelagem cinética, explorando diferentes cinéticas, permitindo um ajuste preciso das transições do modelo contínuo e assegurando o realismo biológico. O terceiro pilar da proposta envolve a determinação dos coeficientes numéricos dos modelos contínuos. Para abordar a dificuldade de obtenção desses parâmetros cinéticos, o trabalho se concentrará na otimização dos coeficientes por meio de técnicas de computação evolucionista. E por último, será realizado um estudo comparativo das técnicas de otimização baseadas em computação evolucionista, como Estratégias Evolutivas e Evolução Diferencial. A análise se dará em termos da qualidade da solução, custo computacional e complexidade algorítmica, visando identificar os métodos mais eficientes para a otimização dos parâmetros cinéticos e, assim, contribuir para o avanço da biologia sistêmica e medicina personalizada. A execução dessas etapas será organizada conforme o cronograma 3.1.

REFERÊNCIAS

- ADEREM, A. Systems biology: its practice and challenges. **Cell**, Elsevier, v. 121, n. 4, p. 511–513, 2005.
- ARNDT, P. F.; VINGRON, M. The otto warburg international summer school and workshop on networks and regulation. **BMC Bioinformatics**, Springer, v. 8, p. 1–2, 2007.
- AUGUSTO, D. A.; BARBOSA, H. J. C. Symbolic regression via genetic programming. **Proceedings. Vol.1. Sixth Brazilian Symposium on Neural Networks**, p. 173–178, 2000. Disponível em: <<https://api.semanticscholar.org/CorpusID:41000755>>.
- BÄCK, T.; FOUSSETTE, C.; KRAUSE, P. **Contemporary evolution strategies**. [S.l.]: Springer, 2013. v. 86.
- BADENHORST, M. et al. Workflow for data analysis in experimental and computational systems biology: using python as ‘glue’. **Processes**, MDPI, v. 7, n. 7, p. 460, 2019.
- BERNARDINO, H. S.; BARBOSA, H. J. C. Comparing two ways of inferring a differential equation model via grammar-based immune programming. In: **Proceedings of the Iberian-Latin-American Congress on Computational Methods in Engineering**. s.l.: s.n., 2010.
- BEYER, H.-G.; SCHWEFEL, H.-P. Evolution strategies—a comprehensive introduction. **Natural computing**, Springer, v. 1, p. 3–52, 2002.
- BISSWANGER, H. **Enzyme kinetics: principles and methods**. [S.l.]: John Wiley & Sons, 2017.
- BORNHOLDT, S. Boolean network models of cellular regulation: prospects and limitations. **Journal of the Royal Society interface**, The Royal Society London, v. 5, n. suppl_1, p. S85–S94, 2008.
- BOYLE, J. Lehninger principles of biochemistry (4th ed.): Nelson, d., and cox, m. **Biochemistry and Molecular Biology Education**, v. 33, n. 1, p. 74–75, 2005. Disponível em: <<https://iubmb.onlinelibrary.wiley.com/doi/abs/10.1002/bmb.2005.494033010419>>.
- CHOCAT, R. et al. Modified covariance matrix adaptation—evolution strategy algorithm for constrained optimization under uncertainty, application to rocket design. **International Journal for Simulation and Multidisciplinary Design Optimization**, EDP Sciences, v. 6, p. A1, 2015.
- COSTA, L.; OLIVEIRA, P. Estratégias evolutivas. Imprensa da Universidade de Coimbra, 2012.
- DARWIN, C. **On the Origin of Species by Means of Natural Selection, or the Preservation of Favoured Races in the Struggle for Life**. London: John Murray, 1859. First edition.
- DASTANPOUR, A.; IBRAHIM, S.; MASHINCHI, M. **Used Genetic Algorithm for Support Artificial Neural Network in Intrusion Detection System**. 2014.
- EIBEN, A.; SMITH, J. **Introduction to Evolutionary Computing**. [S.l.]: Springer, 2015. (Natural Computing Series). Geburtenis: 2nd edition. ISBN 9783662448731.

ELTAEIB, T.; MAHMOOD, A. Differential evolution: A survey and analysis. **Applied Sciences**, MDPI, v. 8, n. 10, p. 1945, 2018.

FONSECA, L. G. d. Algoritmos genéticos assistidos por metamodelos baseados em similaridade. 2009.

GOUTELLE, S. et al. The hill equation: a review of its capabilities in pharmacological modelling. **Fundamental & Clinical Pharmacology**, v. 22, n. 6, p. 633–648, 2008. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1472-8206.2008.00633.x>>.

IMANI, M.; BRAGA-NETO, U. M. Point-based methodology to monitor and control gene regulatory networks via noisy measurements. **IEEE Trans. Control. Syst. Technol.**, v. 27, n. 3, p. 1023–1035, 2019. Disponível em: <<https://doi.org/10.1109/TCST.2017.2789191>>.

JACKSON, C. A. et al. Gene regulatory network reconstruction using single-cell rna sequencing of barcoded genotypes in diverse environments. **Elife**, eLife Sciences Publications Limited, v. 9, p. e51254, 2020.

JOHNSON, K. A.; GOODY, R. S. The original michaelis constant: Translation of the 1913 michaelis–menten paper. **Biochemistry**, v. 50, n. 39, p. 8264–8269, 2011. PMID: 21888353. Disponível em: <<https://doi.org/10.1021/bi201284u>>.

KARLEBACH, G.; SHAMIR, R. Modelling and analysis of gene regulatory networks. **Nature Reviews Molecular Cell Biology**, Nature Publishing Group, v. 9, n. 10, p. 770–780, 2008.

KAUFFMAN, S. A. et al. **The Origins of Order: Self-Organization and Selection in Evolution**. [S.l.]: Oxford University Press, USA, 1993.

KITANO, H. **Foundations of systems biology**. [S.l.]: The MIT Press Cambridge, Massachusetts London, England, 2001.

LACERDA, E. G. de; CARVALHO, A. D. Introdução aos algoritmos genéticos. **Sistemas inteligentes: aplicações a recursos hídricos e ciências ambientais**, v. 1, p. 99–148, 1999.

LEHNINGER, A. L. **Lehninger Principles of Biochemistry: David L. Nelson, Michael M. Cox**. [S.l.]: Recording for the Blind & Dyslexic New York, 2004.

LIKIĆ, V. A. et al. Systems biology: the next frontier for bioinformatics. **Advances in bioinformatics**, Wiley Online Library, v. 2010, n. 1, p. 268925, 2010.

LOPES, H. S.; TAKAHASHI, R. H. C. **Computação evolucionária em problemas de engenharia**. [S.l.]: Omnipax, 2011.

MACHADO, D. et al. Modeling formalisms in systems biology. **AMB Express**, Springer, v. 1, n. 1, p. 45, 2011. Disponível em: <<https://doi.org/10.1186/2191-0855-1-45>>.

MCCALL, M. N. Estimation of gene regulatory networks. **Postdoc journal: a journal of postdoctoral research and postdoctoral affairs**, NIH Public Access, v. 1, n. 1, p. 60, 2013.

MEYER-NIEBERG, S.; BEYER, H.-G. Self-adaptation in evolutionary algorithms. In: **Parameter setting in evolutionary algorithms**. [S.l.]: Springer, 2007. p. 47–75.

MIRJALILI, S.; MIRJALILI, S. Genetic algorithm. **Evolutionary algorithms and neural networks: Theory and applications**, Springer, p. 43–55, 2019.

NIJHOUT, H. F. et al. Systems biology of phenotypic robustness and plasticity. **Integrative and Comparative Biology**, v. 57, n. 2, p. 171–184, 07 2017. ISSN 1540-7063. Disponível em: <<https://doi.org/10.1093/icb/icx076>>.

NOËL, F. **15. Coeficiente de Hill e relação “Concentração-Efeito”**. 2020. <https://sbfte.org.br/wp-content/uploads/2020/01/15_Coeficiente_de_Hill.pdf>. Material de aula/curso.

RADEEF, Z. K. A comparative analysis of michaelis-menten, hill, and allosteric models in drug metabolism. **Iraqi Journal of Industrial Research**, v. 12, n. 1, p. 98–108, 2025.

ROCHA, N. C.; SARAMAGO, S. d. F. P. Estudo de algumas estratégias de evolução diferencial. In: **Congresso de Matemática Aplicada e Computacional, CMAC Sudeste**. [S.l.: s.n.], 2011.

SANGUINETTI, G. et al. Gene regulatory network inference: an
in<https://www.leopoldina.cefetmg.br/roductory> survey. In: **Gene Regulatory Networks**. [S.l.]: Springer, 2019. p. 1–23.

SCHLITT, T.; BRAZMA, A. Current approaches to gene regulatory network modelling. **BMC bioinformatics**, Springer, v. 8, p. 1–22, 2007.

SCHMIDT, M.; LIPSON, H. Data-mining dynamical systems: Automated symbolic system identification for exploratory analysis. **ASME Conf Proc**, v. 2008, 01 2008.

SCHWEFEL, H.-P. Numerische optimierung von computer-modellen mittels der evolutionsstrategie. **(No Title)**, Birkhäuser Basel, 1977.

SILVA, J. E. H. da. **Inferência de Redes de Regulação Gênica a partir de Séries Temporais via Meta-heurísticas**. Tese (Doutorado) — Universidade Federal de Juiz de Fora, Instituto de Ciências Exatas, Programa de Pós-Graduação em Modelagem Computacional, Juiz de Fora, 2024.

SILVA, J. E. H. da et al. Inferring gene regulatory network models from time-series data using metaheuristics. In: **2020 IEEE Congress on Evolutionary Computation (CEC)**. [S.l.]: IEEE, 2020. p. 1–8.

STEUER, R. et al. Structural kinetic modeling of metabolic networks. **Proceedings of the National Academy of Sciences**, National Academy of Sciences, v. 103, n. 32, p. 11868–11873, 2006.

STORN, R.; PRICE, K. Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces. **Journal of global optimization**, Springer, v. 11, p. 341–359, 1997.

VIJESH, N. et al. Modeling of gene regulatory networks: A review. **Journal of Biomedical Science and Engineering**, Scientific Research Publishing, v. 6, n. 02, p. 223, 2013.

WANG, R.-S.; SAADATPOUR, A.; ALBERT, R. Boolean modeling in systems biology: an overview of methodology and applications. **Physical Biology**, v. 9, p. 055001, 09 2012.

WITTMANN, D. M. et al. Transforming boolean models to continuous models: methodology and application to t-cell receptor signaling. **BMC Systems Biology**, BioMed Central, v. 3, n. 1, p. 98, 2009.

XIANG, W.-l. et al. An enhanced differential evolution algorithm based on multiple mutation strategies. **Computational intelligence and neuroscience**, Wiley Online Library, v. 2015, n. 1, p. 285730, 2015.

ZINI, É. d. O. C. Algoritmo genético especializado na resolução de problemas com variáveis contínuas e altamente restritos. Universidade Estadual Paulista (Unesp), 2009.